

Mobility Diary: un sistema Context-Aware per il diario personale di mobilità con Human Activity Recognition

Giacomo Bianco

Dipartimento di Informatica

Università di Bologna

Bologna, Italia

giacomo.bianco4@studio.unibo.it

Abstract—Questo lavoro presenta *Mobility Diary*, una piattaforma context-aware che ricostruisce un diario personale di mobilità a partire da tracce GPS e dati inerziali dello smartphone. Un modello di riconoscimento delle attività individua la modalità di spostamento dell'utente, mentre le posizioni ricorrenti vengono raggruppate automaticamente in luoghi abituali. La posizione dell'utente è protetta da una tecnica di perturbazione spaziale, che genera una vista privata dettagliata e una vista condivisibile meno precisa, con un compromesso tra privacy e qualità del dato misurato sperimentalmente.

I. INTRODUZIONE

Comprendere come le persone si muovono all'interno di un contesto urbano è un problema di crescente interesse, con applicazioni che spaziano dalla pianificazione dei trasporti alla progettazione di servizi personalizzati per il singolo utente. Il semplice tracciamento della posizione, tuttavia, non è sufficiente a cogliere il significato degli spostamenti: una sequenza di coordinate GPS non distingue, ad esempio, tra un tragitto percorso a piedi, in bicicletta o in automobile, né indica se un punto visitato rappresenti un luogo rilevante per l'utente, come la propria abitazione o il luogo di lavoro. Un sistema *context-aware* per la mobilità deve quindi andare oltre la semplice acquisizione di dati grezzi di posizione, arricchendo la traccia con altre informazioni, quali l'attività di movimento riconosciuta e i luoghi significativi frequentati, in modo da trasformare una sequenza di punti GPS in un diario di mobilità realmente informativo.

In questo lavoro presento *Mobility Diary*, un sistema context-aware composto da un'applicazione mobile per la raccolta dei dati di mobilità, un back-end che ne gestisce l'elaborazione e la persistenza, e una dashboard Web per la consultazione del diario. Il sistema integra il riconoscimento dell'attività umana (Human Activity Recognition, HAR) con meccanismi di protezione della privacy sui dati di posizione. Nello specifico, il sistema realizza:

- una pipeline di ingestione asincrona dei dati grezzi raccolti dal dispositivo mobile, basata su un pattern di caricamento diretto verso uno storage a oggetti (MinIO) seguito da una fase di conferma esplicita, che evita che i dati grezzi transitino dal server applicativo, seguito da

un'elaborazione asincrona lato server che materializza la traccia di mobilità;

- la ricostruzione della mobilità dell'utente come sequenza di segmenti temporali, ciascuno associato a un luogo o a un'attività di movimento (cammino, bicicletta, automobile, sosta), a partire dalle tracce raccolte dal dispositivo;
- un modulo di Human Activity Recognition basato su una pipeline a due fasi CNN1D + GRU bidirezionale, addestrata sul dataset pubblico SHL (Sussex-Huawei Locomotion) [1] per riconoscere cinque modalità di mobilità (IDLE, WALKING, RUNNING, BIKING, MOVING_VEHICLE), con un'accuratezza dell'84,88% sul validation set ufficiale;
- la generazione di viste privacy-aware del diario a tre livelli (*precise*, *approximate*, *aggregated*), ottenute tramite una tecnica di generalizzazione spaziale a griglia (spatial cloaking) sulle tracce GPS, con valutazione quantitativa del compromesso tra perturbazione della posizione e qualità del servizio;
- una dashboard Web per la consultazione del diario di mobilità da parte del personale autorizzato, con confronto diretto tra la traccia vera e la traccia perturbata secondo il livello di privacy selezionato.

Il resto dell'articolo è organizzato come segue: la Sezione II descrive l'architettura del sistema, la Sezione III ne dettaglia l'implementazione e la Sezione IV presenta i risultati sperimentali ottenuti.

II. ARCHITETTURA DEL SISTEMA

A. Panoramica

Il sistema è composto da due client, un'applicazione mobile, una dashboard Web e da un back-end raggiungibile attraverso un unico gateway, come mostrato in Fig. 1. Il back-end gestisce sia le operazioni sincrone del diario, sia l'elaborazione asincrona dei dati grezzi caricati dal dispositivo, descritte nel dettaglio nelle sottosezioni seguenti. Il dato nasce sul dispositivo dell'utente, viene caricato verso il back-end e sottoposto a un'elaborazione asincrona che ne estrae informazioni di contesto (attività riconosciuta, luoghi significativi);

viene infine persistito e reso disponibile in lettura, con o senza protezione della privacy, alla dashboard Web.

B. Applicazione mobile

L'applicazione mobile, sviluppata in Flutter, è responsabile della raccolta dei dati sul dispositivo dell'utente. Localmente, l'applicazione determina in autonomia se l'utente è in movimento o fermo, tramite una macchina a stati finiti alimentata dai dati dei sensori, in modo da adattare la frequenza di campionamento in base allo stato ed evitare un'acquisizione continua e costante che porterebbe ad un consumo eccessivo della batteria. I dettagli di questa macchina a stati sono discussi nella Sezione III.

C. Livello di ingresso e servizio applicativo

Le richieste sincrone dell'applicazione mobile e della dashboard attraversano un'unica istanza di gateway (Nginx), che instrada il traffico verso il servizio applicativo, realizzato in Django con Django Ninja e replicato su due istanze per poter servire richieste concorrenti. Questo livello espone le principali operazioni sincrone del sistema: autenticazione dell'applicazione mobile e della dashboard, lettura del diario giornaliero e delle tracce di mobilità, gestione dei luoghi significativi (conferma, rifiuto, etichettatura), consultazione delle statistiche personali, gestione delle preferenze di privacy ed esportazione privacy-aware del diario, oltre alla gestione degli utenti lato dashboard. È inoltre responsabile di schedulare nella coda di messaggi i task relativi alle operazioni che richiedono un'elaborazione asincrona.

D. Pipeline di ingestione ed elaborazione

Il caricamento dei dati grezzi raccolti dal dispositivo non avviene attraverso il servizio applicativo, ma tramite un pattern di caricamento diretto verso uno storage a oggetti, seguito da una fase di conferma esplicita verso il back-end. Questa scelta evita che il servizio applicativo non debba occuparsi del trasferimento di dati che potrebbero occupare a lungo le sue connessioni, saturandone la capacità di servire richieste concorrenti: il suo ruolo si limita ad autorizzare il caricamento e a confermarne il completamento, mentre il trasferimento dei dati avviene direttamente tra dispositivo e storage.

Una volta confermato il caricamento, il dato viene preso in carico dal livello di elaborazione asincrona (Celery), disaccoppiato dal servizio applicativo tramite una coda di messaggi (Redis). L'elaborazione avviene in quattro fasi in sequenza, ciascuna dipendente dall'output della precedente:

1) *Classificazione dell'attività*: Etichetta le finestre di dati sensoriali presenti nello storage con la modalità di movimento riconosciuta.

2) *Inserimento nel diario*: Materializza la traccia di mobilità, i relativi segmenti e le etichette di movimento a partire dai dati caricati e dalle etichette prodotte al passo precedente.

3) *Inserimento batch dei dati sensoriali*: Persiste le misure grezze nel database (TimescaleDB).

4) *Analisi dei luoghi abituali*: Individua i luoghi significativi frequentati dall'utente a partire dai dati di posizione inseriti nel diario.

La natura asincrona di queste quattro fasi permette di gestire carichi di lavoro computazionalmente costosi (in particolare fase 1 e fase 3) senza impattare la latenza delle richieste sincrone del servizio applicativo. I dettagli realizzativi di ciascuna fase sono discussi nella Sezione III.

E. Persistenza

Il sistema utilizza due meccanismi di persistenza distinti, scelti in base alla natura del dato. I dati strutturati del diario, ovvero tracce, segmenti, luoghi significativi ed etichette di attività, sono memorizzati in un database relazionale esteso con PostGIS [2] e TimescaleDB [3], che permettono di eseguire query geografiche e query di analisi pesanti basate su aggregazioni. I dati grezzi provenienti dai sensori, che non necessitano di essere interrogati singolarmente ma solo recuperati per intero durante l'elaborazione asincrona, sono invece mantenuti in uno storage a oggetti separato dal database.

F. Modello dei dati

Le entità richieste dalla traccia sono rappresentate nel modello persistente con i nomi riportati nella Tabella I. La separazione tra traccia, segmenti e luoghi consente di conservare l'evidenza grezza e di ricostruire una vista del diario aggiornata quando cambiano le etichette dei luoghi.

I campioni inerziali sono inoltre conservati in `RawSensorReading`; le transizioni della macchina a stati in `StateTransition`; lo stato della lavorazione asincrona in `HarJob` e `TripUpload`. Queste entità sono operative e non modificano il vocabolario di dominio richiesto dalla traccia.

G. Dashboard

La dashboard Web, realizzata in Vue, non è pensata per l'utente finale ma per un amministratore: consente di selezionare un utente da un elenco e di ispezionarne il diario di mobilità a fini di supporto e verifica. Consuma le API sincrone esposte dal servizio applicativo per mostrare, per l'utente selezionato, le tracce di mobilità e i luoghi significativi su mappa, il diario giornaliero in forma tabellare e temporale, e le statistiche aggregate sulle attività riconosciute prodotte dalla fase di data mining della pipeline. Permette inoltre di confrontare la traccia reale con la corrispondente vista privacy-aware, e di filtrare i dati mostrati per giorno, attività riconosciuta, viaggio o intervallo temporale.

H. Containerizzazione

L'intera piattaforma server è avviabile con Docker Compose. Un gateway Nginx costituisce l'unico ingresso HTTP e instrada `/api`, `/admin` e i file statici verso Django, gli oggetti caricati verso MinIO e le restanti richieste verso la single-page application Vue. Completano lo stack PostgreSQL con PostGIS, Redis, i worker Celery.




Fig. 1. Architettura ad alto livello del sistema

TABLE I
CORRISPONDENZA TRA LE ENTITÀ DELLA TRACCIA E IL MODELLO IMPLEMENTATO

Entità concettuale	Modello implementato	Significato e attributi principali
MobilityTrace	Trip, GpsPoint	Un Trip delimita una sessione di mobilità e conserva stato, intervallo temporale, distanza e percorso LineString. I GpsPoint mantengono timestamp, coordinate PostGIS, velocità e accuratezza della misura.
MobilitySegment	MobilitySegment	Una riga persistente del diario, di tipo MOVE o STOP, con inizio, fine, attività riconosciuta, distanza e percorso opzionale.
SignificantPlace	HabitualPlace CandidateVisit	Una CandidateVisit rappresenta una singola permanenza; visite spazialmente ricorrenti vengono aggregate in un HabitualPlace, con centro, raggio, conteggi, stato di revisione, categoria e nome scelto dall'utente.
ActivityLabel	ActivityLabel	Vocabolario controllato condiviso dai segmenti e dal classificatore: IDLE, WALKING, RUNNING, BIKING e MOVING_VEHICLE.

III. IMPLEMENTAZIONE

A. Applicazione mobile

L'intero codice dell'applicazione mobile è organizzato seguendo Pine, un'architettura per progetti Flutter che separa in layer distinti la UI, la logica di state management (Cubit/BLoC), i repository e i servizi esterni, con dipendenze che attraversano i layer in una sola direzione [9]. Le sottosezioni seguenti descrivono i moduli applicativi costruiti sopra questa struttura.

1) *Macchina a stati finiti di rilevamento del movimento*: L'applicazione è pensata per restare in esecuzione anche per diverse ore nell'arco della giornata, il che rende il consumo energetico un vincolo di progettazione non trascurabile. Durante l'intero utilizzo, il sistema mantiene attivi tre stream di sensori: accelerometro, giroscopio e GPS. Per contenere

il consumo energetico senza rinunciare alla qualità del dato, l'applicazione mantiene localmente una macchina a stati finiti che determina se l'utente è in movimento (*movement*) o fermo (*stationary*) (Sezione II), e associa a ciascuno dei due stati un profilo di campionamento diverso, riducendo la frequenza di acquisizione quando l'utente è fermo.

Per decidere se cambiare stato, la macchina osserva due valori: la velocità istantanea fornita dal GPS e σ , la deviazione standard della Signal Vector Magnitude (SVM) dell'accelerometro, la SVM di un campione è $\sqrt{x^2 + y^2 + z^2}$ sulle tre componenti dell'accelerazione. σ non viene ricalcolato a ogni singolo campione dell'accelerometro, ma accumulando i campioni in una finestra e calcolandolo una sola volta al suo completamento: 20 campioni (2 s a 10 Hz) nello stato *stationary*, 500 campioni (5 s a 100 Hz, la stessa finestra usata per la classificazione HAR) nello stato *movement*.




Fig. 2. Macchina a stati finiti di rilevamento del movimento: stati, transizioni ed effetto di ciascun tipo di evidenza sui timer di isteresi

All'avvio di un viaggio la macchina viene inizializzata nello stato *stationary*. In questo stato il profilo di campionamento imposta l'accelerometro a 10 Hz e disattiva il giroscopio (attivo invece a 100 Hz in *movement*, dove alimenta le finestre sensoriali per la classificazione HAR); il GPS, in entrambi gli stati, non campiona a una frequenza fissa ma emette un nuovo fix quando l'utente si sposta di almeno 3 m dall'ultima posizione nota. Una soglia di spostamento più piccola produrrebbe un numero di fix eccessivo rispetto alla precisione del GPS, che finirebbero comunque tutti persistiti nel database, aumentando il volume di dati archiviati senza un beneficio proporzionale sulla qualità della traccia. La Tabella II riassume la frequenza dei tre sensori nei due stati, e dopo quanti dati ciascuno produce l'evento che fa scattare una nuova valutazione della macchina a stati, cioè un nuovo calcolo dell'evidenza (movimento, sosta o incerta) a partire dal dato appena arrivato.

TABLE II
FREQUENZA DEI SENSORI E GENERAZIONE DEGLI EVENTI PER LA
MACCHINA A STATI

Sensore	station.	movem.	Innesca una valutazione dopo
Accelerometro	10 Hz	100 Hz	20 campioni (2 s) in stationary; 500 in movement (5 s)
Giroscopio	spento	100 Hz	non alimenta la FSM: solo finestre HAR
GPS	a evento (3 m)	a evento (3 m)	immediato, a ogni fix

Accelerometro e GPS sono quindi due processi indipendenti e asincroni: ogni volta che uno dei due produce un nuovo dato, la macchina rivaluta lo stato corrente combinando quel dato con l'ultimo valore noto dell'altro segnale, entrambi soggetti a un controllo di freschezza (rispettivamente 10 s e 20 s) che considera assente un dato più vecchio della soglia. Il risultato di questa valutazione è un'evidenza, movimento, sosta o incerta, ottenuta confrontando σ e la velocità GPS con soglie fisse.

Le soglie non sono le stesse in ogni situazione. Una velocità GPS pari o superiore a 2.5 m/s è considerata da sola sufficiente a dichiarare evidenza di movimento, indipendentemente da σ , poiché compatibile solo con un veicolo. Al di sotto di questa soglia, se lo stato corrente è *movement* la decisione si basa solo su σ : valori pari o superiori a 1.2 indicano movimento, valori inferiori a 0.8 indicano sosta, i valori intermedi restano incerti. Viene data priorità a σ per due motivi legati fra loro: quando la macchina a stati si trova in *movement* e deve stabilirne se l'utente si è davvero fermato, la sosta avviene tipicamente in un luogo chiuso, dove il GPS diventa meno preciso; inoltre, se l'utente è realmente fermo, il filtro di distanza di 3 m descritto sopra fa sì che il GPS smetta proprio di inviare nuovi dati. Il segnale GPS quindi non solo perde precisione ma smette di fornire nuova informazione proprio nel momento in cui servirebbe per confermare la sosta, mentre l'accelerometro resta affidabile. Se invece lo stato corrente è *stationary*, la macchina a stati richiede che σ e la velocità GPS concordino: evidenza di movimento solo se $\sigma \geq 1.2$ e velocità ≥ 0.8 m/s, evidenza di sosta solo se $\sigma < 0.8$ e velocità < 0.5 m/s; in tutti gli altri casi l'evidenza resta incerta. Questo requisito più stringente nello stato *stationary* riduce i falsi positivi che un singolo segnale rumoroso potrebbe generare quando l'utente è effettivamente fermo: il sistema è pensato proprio per non segnalare come movimento i piccoli spostamenti tipici di un ambiente chiuso, come pochi passi in casa o in palestra. A questo si aggiunge un vincolo temporale: le transizioni di stato sono soggette a un tempo di conferma minimo asimmetrico, che richiede un'evidenza sostenuta per un tempo minimo prima di confermare il cambio di stato. Questo è un ulteriore filtro contro i micro-spostamenti, che raramente durano abbastanza a lungo da superarla. Da *stationary* a *movement* sono richiesti 10 s di evidenza di movimento sostenuta, mentre da *movement* a *stationary* ne sono richiesti 120 s. Questa asimmetria evita che una breve sosta durante uno spostamento (ad esempio a un semaforo) chiuda prematuramente un segmento di movimento. Ad ogni tran-

sizione, la macchina aggiorna il profilo di campionamento dei sensori. Quando lo stato diventa *movement*, il cambiamento è drastico: il filtro del GPS resta invariato, ma il giroscopio si accende e accelerometro e giroscopio passano entrambi a 100Hz. Questa frequenza non è arbitraria, ma coincide con quella dei dati del dataset SHL usato per addestrare il modello di Human Activity Recognition (Sezione III), poiché le finestre sensoriali raccolte in questo stato sono quelle poi effettivamente classificate dal modello. La Fig. 2 riassume gli stati, le transizioni e tutti i casi di evidenza gestiti dalla macchina.

2) *Rapporto tra macchina a stati e sistema HAR*: La macchina a stati e il sistema di Human Activity Recognition non hanno lo stesso peso nella costruzione del diario: la macchina a stati è la prima fonte di verità. Un segmento temporale che la macchina ha classificato come *stationary* viene considerato sosta ed è preso per buono come tale nel diario finale; il sistema HAR non interviene su questi segmenti. Il suo ruolo si limita a classificare la modalità di movimento all'interno dei soli intervalli di tempo che la macchina a stati ha già decretato come *movement*.

Questa gerarchia si riflette direttamente su cosa viene persistito localmente sul dispositivo. Le finestre di dati di accelerometro e giroscopio, destinate alla classificazione HAR, vengono scritte nel database locale (SQLite) solo durante le fasi in cui la macchina a stati ha dichiarato *movement*: quando lo stato è *stationary* i dati dei sensori (solo l'accelerometro, poiché il giroscopio è spento) vengono usati esclusivamente per la decisione della macchina stessa e non generano alcuna finestra da salvare. Questo non esclude che, all'interno di una finestra classificata come *movement*, il sistema HAR possa poi riconoscere sotto-intervalli in cui l'utente è di fatto fermo (ad esempio una breve sosta a un semaforo); questo caso è discusso più avanti (Sezione III).

I dati del GPS seguono invece una logica diversa: vengono registrati per tutta la durata del viaggio, incluse le fasi di sosta. Vengono comunque sempre persistiti perché sono necessari a ricostruire il viaggio nella sua interezza, anche dal punto di vista grafico sulla mappa. La Fig. 3 riassume, lungo un viaggio composto da tre segmenti consecutivi, quali dati vengono effettivamente persistiti localmente in SQLite in ciascuna fase, prima di essere caricati e incorporati dal back-end secondo la pipeline di ingestione descritta in Sezione II-D.




Fig. 3. Dati persistiti localmente in SQLite lungo un viaggio composto da tre segmenti: nelle fasi *stationary* viene salvato solo il GPS, mentre nella fase *movement* vengono salvati anche accelerometro e giroscopio, usati per la classificazione HAR.

3) *Struttura e impacchettamento dei dati sensoriali per l'HAR*: Come descritto in Sezione II, nello stato *movement* accelerometro e giroscopio campionano entrambi a 100Hz. Ogni 5 s di campioni viene raggruppato in una finestra, ovvero una matrice 500×6 : 500 campioni temporali per le sei componenti Acc_x, Acc_y, Acc_z, Gyr_x, Gyr_y, Gyr_z. Localmente, ogni finestra è persistita come una singola riga della tabella *SensorWindows* del database SQLite: la matrice è serializzata in formato JSON nella colonna *matrixJson*, accompagnata da metadati (timestamp di inizio e fine, numero di campioni, frequenza).

Al momento della sincronizzazione, le finestre non vengono caricate una alla volta né tutte insieme, ma raggruppate in più file. Le righe della tabella vengono lette dal database a pagine di 128 finestre e accumulate in un buffer finché la loro dimensione, misurata sul JSON non compresso, non supera la soglia di 12 MB; a quel punto il buffer viene scritto su un file e se ne apre uno nuovo. Ogni finestra pesa circa 29 KB da non compressa: il JSON è testo, e ogni valore viene prima arrotondato a sei decimali, ad esempio per una singola riga a sei canali:

```
[−0.023457, −9.806649, 0.112346,
0.001235, −0.004321, 0.000765]
```

Con valori di questa forma, una riga pesa circa 58 caratteri (51 per i sei numeri più 7 tra virgole e parentesi), pari a circa 58 byte in UTF-8, dove ogni cifra o simbolo occupa esattamente un byte; su 500 righe per finestra si ottengono circa 29000 byte. Un file da 12 MB contiene quindi approssimativamente 430 finestre (circa 36 minuti di registrazione). Questo valore è tenuto volutamente basso per limitare il picco di memoria della serializzazione sul telefono, indipendentemente dalla durata complessiva del viaggio.

Ogni file viene poi compresso con GZIP, un formato di compressione senza perdita basato sull'algoritmo DEFLATE: riduce la dimensione del file individuando e codificando in modo più compatto le ripetizioni nei dati, il che si adatta bene a un JSON con una struttura molto regolare come questo, dimezzandone circa la dimensione (i 12 MB non compressi diventano circa 5 MB). L'intera operazione, ovvero compressione e calcolo del checksum SHA-256, viene eseguita in un isolate separato dall'interfaccia utente, il meccanismo di Flutter per eseguire codice su un thread indipendente, questo evita che un calcolo pesante come questo possa bloccare il rendering dell'interfaccia. Il checksum calcolato serve alla successiva fase di conferma dell'upload (Sezione III): la stringa SHA-256 calcolata localmente viene inviata al back-end insieme al file, che la confronta con il checksum calcolato sul file effettivamente ricevuto sullo storage, per verificare che corrispondano.

4) *Coda di sincronizzazione offline*: I dati raccolti localmente vengono sincronizzati verso il back-end attraverso la tabella *SyncJobs* del database SQLite locale, un record della quale gestisce di fatto una coda di sincronizzazione: ogni sessione di raccolta genera un job, elaborato in ordine cronologico, i più vecchi per primi, uno alla volta, per evitare di saturare la connessione con più sessioni in parallelo.

Il caricamento di ogni job avviene in due fasi. Nella fase *core*, i punti GPS raccolti e i cambiamenti di stato tra *movement* e *stationary* vengono inviati con una richiesta diretta al servizio API, senza passare per lo storage a oggetti. Nella fase *raw*, vengono invece caricati i file prodotti come descritto nella sottosezione precedente, secondo il pattern di caricamento diretto con conferma descritto in Sezione II-D: ciascuna parte viene prima autorizzata dal back-end, poi caricata e infine confermata con il relativo checksum. Ogni job traccia separatamente lo stato delle due fasi, che possono essere confermate e ritentate in modo indipendente; le parti *raw* vengono caricate a gruppi di tre in parallelo, anziché una alla volta, per ridurre il tempo complessivo di sincronizzazione.

La coda gestisce esplicitamente i casi in cui il back-end sta ancora elaborando in modo asincrono i dati ricevuti, mettendo il job in attesa e ripetendo il controllo dello stato a intervalli regolari. In caso di errore, il job viene ritentato con un ritardo crescente (10s, 30s, 2min, 10min) fino a un massimo di cinque tentativi, oltre i quali viene scartato; un job scartato per cui il back-end ha già creato una traccia viene inoltre annullato lato server, per non lasciare dati parziali orfani. Al completamento con successo, i file temporanei locali vengono eliminati e la sessione viene rimossa dal database locale, mantenendo limitato lo spazio occupato sul dispositivo.

5) *Vincolo di un viaggio attivo alla volta*: Il sistema è pensato attorno a un'unica linea temporale per utente: il diario è una sequenza di viaggi consecutivi, e non ha senso, in questo modello, che due viaggi risultino in corso nello stesso momento. Questo vincolo è realizzato facendo sì che, nel momento in cui l'utente preme Start, venga già creato lato back-end un record del viaggio, con data di inizio e dispositivo associato, anche se in quel momento i dati non vengono ancora inviati: l'invio effettivo di tracce GPS e dati sensoriali non è progressivo durante la registrazione, ma avviene tutto in blocco solo alla pressione di Stop, secondo la coda di sincronizzazione descritta in precedenza.

L'esistenza di questo record fin dall'avvio è ciò che permette di far rispettare il vincolo: se l'utente prova ad avviare un nuovo viaggio da un dispositivo diverso mentre, sullo stesso account, un viaggio risulta già avviato e non ancora concluso, il back-end rifiuta la richiesta, impedendo che due registrazioni si sovrappongano sulla stessa linea temporale.

Durante il viaggio, l'applicazione invia inoltre al back-end un segnale di *heartbeat* ogni 5 minuti, che aggiorna un dato di freschezza associato al viaggio in corso. Questo meccanismo protegge da un caso limite: un viaggio che risulti ancora attivo ma che in realtà non riceva aggiornamenti da troppo tempo. Se un viaggio attivo resta senza *heartbeat* per più di 24 ore, viene chiuso automaticamente non appena l'utente prova ad avviarne uno nuovo, da un altro dispositivo o dallo stesso, permettendo alla registrazione di ripartire anziché restare bloccata indefinitamente da un viaggio ormai inattivo.

6) *Visualizzazione progressiva dei risultati*: Riprendendo le due fasi di caricamento (*core* e *raw*) e le quattro fasi asincrone di elaborazione descritte in Sezione II-D, l'applicazione

mobile non attende il completamento dell'intera pipeline per mostrare all'utente il viaggio appena registrato. Non appena la fase *core* è confermata, l'applicazione mostra subito la mappa del viaggio nella sua interezza, costruita a partire dai punti GPS caricati in quella fase: è l'informazione più immediata da mostrare, ed è già disponibile lato back-end a quel punto.

Per ottenere il diario con i segmenti colorati in base alla modalità di movimento, l'applicazione effettua invece un polling verso il back-end con cadenza di un secondo, richiedendo a ogni chiamata lo stato di elaborazione del viaggio. Il back-end restituisce il diario come completo solo quando il viaggio risulta processato, condizione che si verifica nel momento in cui le fasi 1 e 2 della pipeline asincrona, classificazione dell'attività e inserimento nel diario, sono terminate; le fasi 3 e 4, inserimento batch dei dati sensoriali e data mining dei luoghi abituali, non sono invece necessarie per mostrare il diario e proseguono indipendentemente. Il punto rilevante è quindi che l'utente non deve attendere il completamento dell'intera elaborazione asincrona per vedere, graficamente, l'esito del proprio viaggio, ma solo il termine delle prime due fasi: questo riduce sensibilmente il tempo di caricamento percepito rispetto all'attesa dell'intera pipeline. La Fig. 4 riassume l'intera pipeline, dalla pressione di Stop fino al completamento del data mining, insieme ai due momenti in cui l'utente vede effettivamente qualcosa cambiare nell'interfaccia.

7) *Gestione dell'applicazione in background*:

L'applicazione è pensata per un utilizzo prolungato nell'arco della giornata: l'utente preme Start e lascia l'app in esecuzione, spesso in background, per diverse ore. In questa condizione l'applicazione deve gestire con attenzione sia il caso in cui il sistema operativo la sospenda, sia più semplicemente il caso in cui l'utente non vi torni per diversi minuti. La continuità della raccolta dati in questi stati non è garantita allo stesso modo per tutti i sensori: i permessi di localizzazione in background permettono di continuare a ricevere fix GPS, ma le librerie usate per accelerometro e giroscopio non possono garantire che i campioni continuino ad arrivare in ogni condizione di background del sistema operativo.

Per questo motivo, quando l'utente torna nell'applicazione dopo un'assenza, il sistema confronta i timestamp dell'ultima transizione di stato, dell'ultimo punto GPS e dell'ultima finestra sensoriale registrati localmente, e prende il più recente dei tre come istante dell'ultima attività nota. Se da quell'istante sono trascorsi almeno 30 minuti, la sessione viene considerata autoconclusa: viene chiusa retroattivamente, con istante di fine impostato a quell'ultima attività nota anziché al momento della riapertura, e inviata al back-end come se il viaggio si fosse concluso in quel momento. Se invece sono trascorsi meno di 30 minuti, la sessione viene ripresa normalmente. In questo caso, tuttavia, il sistema effettua una correzione: se l'ultimo stato noto della macchina era *movement*, ma nel frattempo i dati dei sensori hanno smesso di arrivare, quel *movement* non è più considerato affidabile, non essendoci conferma recente che l'utente sia ancora in movimento e il sistema forza lo stato a *stationary* a partire da quando i dati si sono interrotti;




Fig. 4. Pipeline completa di caricamento ed elaborazione

la macchina a stati riprende quindi da questo stato corretto, anziché dall'ultimo realmente osservato.

Questo meccanismo lato mobile, però, non basta da solo: può comunque capitare che un segmento venga classificato dalla macchina a stati come *movement*, ma che i dati sensoriali corrispondenti a quell'intervallo non siano di fatto disponibili. Per questo esiste un'ulteriore rete di sicurezza lato back-end: quando, durante la costruzione del diario, un segmento di movimento non ha finestre HAR classificate al suo interno, il sistema non lo lascia privo di etichetta, ma stima l'attività a partire dalla velocità mediana registrata dai punti GPS in quell'intervallo, classificandola secondo soglie fisse (a piedi sotto gli 8 km/h, di corsa fino a 13 km/h, in bicicletta fino a 25 km/h, altrimenti in veicolo).

B. Route assistant context-aware

L'assistente di percorso usa come punto A la posizione GPS corrente e consente all'utente di cercare e selezionare un punto B tramite il geocoding Mapbox. La richiesta [4] usa uno dei tre profili *walking*, *cycling* e *driving*; la risposta GeoJSON viene mostrata sulla mappa insieme a distanza e durata stimate. Il profilo può essere scelto manualmente oppure derivato dal modulo HAR: *WALKING* e *RUNNING* diventano *walking*, *BIKING* diventa *cycling*, mentre *MOVING_VEHICLE* diventa *driving*.

Quando è attiva la modalità live, ogni 15 secondi il client preleva l'ultima finestra inerziale 500×6 e la invia all'endpoint di classificazione. Se la modalità riconosciuta cambia, lo stato del client viene aggiornato e la rotta viene nuovamente richiesta usando il profilo coerente. Il ricalcolo usa anche la posizione corrente più recente, perciò reagisce sia a un cambio del mezzo sia allo spostamento dell'utente. Contatori di generazione associati alle richieste di geocoding e routing impediscono a risposte asincrone obsolete di sovrascrivere una scelta più recente.

C. Classificazione dell'attività (HAR)

1) *Dataset e preparazione*: Il modulo HAR è addestrato sul dataset pubblico SHL (Sussex-Huawei Locomotion) [1], raccolto con smartphone Huawei indossati simultaneamente in quattro posizioni del corpo (tasca, borsa, petto, mano). Ogni posizione registra a 100Hz accelerometro, giroscopio e

magnetometro, già pre-segmentati in finestre da 500 campioni (5 s).

Le otto classi originali del dataset (*IDLE*, *WALKING*, *RUNNING*, *DRIVING*, *BIKING*, *BUS*, *TRAIN*, *SUBWAY*) sono state ridotte a cinque, fondendo le quattro modalità di trasporto motorizzato in un'unica classe *MOVING_VEHICLE*: le confusioni tra queste modalità erano numerose (le firme inerziali di un'auto e di un mezzo pubblico sono molto simili) e la fusione le trasforma da errori in predizioni corrette, senza eliminare informazione utile al sistema, che non deve distinguere tra mezzi di trasporto motorizzati diversi.

Il protocollo adottato usa il training set ufficiale, riserva la sua ultima porzione temporale (15%) all'early stopping e impiega il validation set ufficiale solo per la valutazione finale.

2) *Architettura del modello*: Il classificatore di base è una CNN1D che scorre lungo il tempo, leggendo tutti i canali dei sensori a ogni passo: due blocchi convoluzione+pooling (*Conv1D(64)*, *Conv1D(128)*, kernel 10, con *MaxPooling1D*) seguiti da un *Dense(128)* e da uno strato di uscita softmax sulle cinque classi, per circa 2 milioni di parametri complessivi.

L'ingresso è la finestra grezza 500×6 di accelerometro e giroscopio.

I filtri convoluzionali apprendono pattern locali discriminanti e il livello denso li comprime in un embedding di 128 valori.

Una GRU (Gated Recurrent Unit) [6] è un tipo di rete neurale ricorrente pensata per elaborare sequenze: a differenza della CNN, che classifica ogni finestra di 5 s isolatamente, la GRU mantiene uno stato interno che si aggiorna finestra dopo finestra, condizionando la predizione corrente sul contesto delle finestre vicine. I suoi due gate (reset e update) regolano quanta informazione dello stato precedente mantenere o scartare, permettendole di catturare dipendenze anche su sequenze relativamente lunghe con meno parametri di una LSTM equivalente.

Nel sistema la GRU è bidirezionale: legge la sequenza di embedding sia in avanti sia all'indietro, in modo che la predizione su una finestra sfrutti sia il contesto precedente sia quello successivo. Questo è il motivo per cui è stata scelta al posto della sola CNN: una finestra isolata non basta a distinguere, ad esempio, un veicolo fermo nel traffico (circondato da altre finestre di guida) da una persona ferma

(circondata da cammino), un caso di ambiguità discusso nel dettaglio in Sezione IV-B, mentre il contesto temporale fornito dalla GRU rende questa distinzione possibile.

Una normalizzazione per-canale, calcolata solo sul training set e riapplicata a validation e test, e una *focal loss* contrastano lo sbilanciamento delle classi (`MOVING_VEHICLE` è circa il 51% dei dati, pesando di più gli esempi rari e quelli difficili).

D. Inserimento nel diario e persistenza dei dati sensoriali

1) *Rappresentazione geospaziale e query di distanza*: Tutti i dati geospaziali del sistema, i punti GPS, il percorso di ogni segmento, i centroidi delle visite e dei luoghi abituali, sono salvati nel database non come geometria piana, ma con il tipo *geography* di PostGIS (SRID 4326). Questa scelta permette a PostGIS di calcolare le operazioni geospaziali tenendo conto della curvatura della Terra, invece di trattare latitudine e longitudine come coordinate su un piano: in particolare, la lunghezza di un percorso salvato come `LineString` può essere ottenuta con una singola funzione (`ST_Length` su *geografia*), che restituisce direttamente una distanza geodetica in metri, senza che l'applicazione debba implementare a mano formule di distanza tra coordinate. Questa funzione viene usata ripetutamente nel sistema: per calcolare la distanza di ogni segmento di movimento appena costruito, per confrontare la lunghezza di un percorso con quella della sua versione *privacy-aware* (Sezione III), e più in generale ogni volta che serve una misura di distanza reale a partire da una geometria salvata.

2) *Segmentazione del diario*: Nella prima fase di segmentazione del diario, il sistema usa le transizioni della macchina a stati (Sezione III) per individuare macro-intervalli `STOP/MOVE`: gli intervalli `STOP` diventano segmenti di sosta senza bisogno di ulteriore elaborazione, poiché la macchina a stati è già la fonte di verità per la sosta. Gli intervalli `MOVE`, al contrario, vengono affinati in un secondo passo usando le etichette prodotte dal modulo HAR sulle finestre sensoriali che ricadono in quell'intervallo.

Questo affinamento applica due correzioni, a due scale temporali diverse, per distinguere il rumore del classificatore da vere pause nel movimento. La prima corregge cambi di etichetta isolati e brevi: se un gruppo di finestre con un'etichetta diversa è compreso tra due gruppi con la stessa etichetta e dura meno di 60s, viene riassegnato all'etichetta circostante, assumendo che sia un errore di classificazione piuttosto che un cambio di attività reale. La seconda distingue le soste vere da quelle spurie all'interno di un movimento, ed è motivata da un limite intrinseco della macchina a stati stessa: per dichiarare una sosta, la macchina richiede almeno 120s di evidenza di quiete sostenuta (Sezione III). Durante quei 120s, però, il dispositivo continua comunque a raccogliere e classificare finestre sensoriali, ed è molto probabile che il modulo HAR le etichetti correttamente come `IDLE`, perché l'utente è di fatto già fermo, anche se il macro-segmento costruito dalla macchina a stati etichetta ancora quell'intervallo come `movement`, non avendo essa stessa completato la propria isteresi. Per questo, un gruppo di finestre classificate `IDLE` che dura abbastanza viene riconosciuto come sosta reale

e diventa una *pausa virtuale*; un `IDLE` più breve viene invece assorbito nell'etichetta di movimento circostante, trattato come rumore del classificatore. I gruppi risultanti, se adiacenti nel tempo e con la stessa etichetta, vengono infine uniti in un unico segmento (Fig. 5).




Fig. 5. Correzione di un cambio di etichetta isolato e breve (durata < 60 s): il gruppo centrale viene riassegnato all'etichetta circostante.

La distinzione tra pausa virtuale e sosta vera resta interna alla fase di segmentazione: nel diario finale mostrato all'utente le due vengono trattate allo stesso modo, e unite in un'unica sosta (Fig. 6).




Fig. 6. Una pausa virtuale rilevata dentro un macro-segmento `movement` viene unita, nel diario finale, alla sosta `stationary` adiacente decisa dalla FSM.

3) *Persistenza dei dati sensoriali grezzi*: Una volta completata la costruzione del diario (fasi 1 e 2 della pipeline, Sezione II-D), la terza fase inserisce i dati sensoriali grezzi caricati dal dispositivo nel database delle serie temporali. Qui ogni singolo campione di accelerometro e giroscopio diventa una riga a sé.

L'inserimento avviene tramite `bulk_create` a blocchi di 5.000 righe. Il vantaggio di questa rappresentazione riga per campione si osserva nell'utilizzo analitico che se ne fa.

4) *Utilizzo analitico dei dati sensoriali grezzi*: Inserire i dati grezzi riga per campione in un database rende possibile interrogarli direttamente con query SQL. Il sistema sfrutta questa possibilità per effettuare due analisi visibili dal pannello admin.

La prima query individua eventuali buchi anomali nella registrazione di un singolo viaggio: va a confrontare ogni singolo campione di accelerometro e giroscopio con il precedente all'interno dello stesso segmento di movimento, segnalando intervalli temporali superiori a 10 ms (considerando che i campioni sono acquisiti a una frequenza di 100 Hz).

La seconda query calcola, per ciascuna modalità di attività riconosciuta, la media e la deviazione standard delle sei

componenti di accelerometro e giroscopio, considerando tutti i viaggi dell'utente.

E. Data mining dei luoghi abituali

L'individuazione dei luoghi abituali avviene in due fasi successive: prima un rilevamento delle soste (*stay detection*) sui punti GPS grezzi, poi un raggruppamento spaziale di queste soste in luoghi ricorrenti tramite DBSCAN. La prima fase è necessaria perché DBSCAN, di per sé, raggruppa i punti solo in base alla vicinanza spaziale e non tiene conto della dimensione temporale: da solo non può distinguere punti densi perché l'utente è rimasto fermo a lungo in un unico luogo da punti densi perché l'utente vi è tornato più volte in giorni diversi.

La prima fase scorre tutti i punti GPS di un utente in ordine temporale, scartando quelli con precisione peggiore di 60 m, e accumula un cluster di punti consecutivi finché ciascun nuovo punto resta entro 75 m dal centroide corrente del cluster e il tempo trascorso dall'ultimo punto non supera i 90 minuti; al primo punto troppo lontano o dopo un buco temporale troppo lungo, il cluster viene chiuso e se ne inizia uno nuovo. Un cluster diventa una *visita* candidata solo se contiene almeno 3 punti e copre almeno 5 minuti, condizioni che scartano soste troppo brevi.

Le visite individuate vengono poi raggruppate spazialmente con DBSCAN [7]. Per ogni cluster risultante vengono calcolati il centroide, il raggio (la distanza massima tra il centroide e una visita del cluster) e il numero di giorni distinti in cui è stata osservata una visita. Un cluster di punti individuato dal DBSCAN viene promosso a possibile luogo abituale solo se le visite coprono almeno 2 giorni distinti, ed è promosso automaticamente a confermato quando ne raggiunge almeno 4, altrimenti resta in attesa di revisione manuale da parte dell'utente tramite la dashboard. La Fig. 7 riassume l'intera pipeline, dai punti GPS grezzi al ciclo di vita del luogo abituale.

I luoghi confermati vengono infine usati in lettura per arricchire il diario: a ogni segmento di sosta (reale o pausa virtuale) viene associato, se esiste, il luogo confermato più vicino al suo centroide GPS.

Questa dipendenza in lettura ha una conseguenza diretta su come il diario privato viene servito: non esiste, in senso stretto, una versione definitiva e già pronta del diario da restituire, perché il suo contenuto dipende anche dai luoghi abituali dell'utente, che possono cambiare nel tempo indipendentemente dal viaggio stesso, ad esempio quando l'utente conferma, rifiuta o rietichetta un luogo dalla dashboard. Per questo il diario privato è tenuto in una cache (Redis), ma la chiave di cache include, oltre all'identificativo del viaggio, un contatore di versione dei luoghi dell'utente: ogni revisione di un luogo incrementa questo contatore, e la cache esistente diventa automaticamente irraggiungibile con la nuova chiave, senza bisogno di invalidarla esplicitamente.

F. Modulo di privacy

Delle tre viste del diario (*precise*, *approximate*, *aggregated*, Sezione II), solo le ultime due applicano davvero




Fig. 7. Pipeline di individuazione dei luoghi abituali: dai punti GPS grezzi alla stay detection, al raggruppamento DBSCAN, fino al ciclo di vita candidate/confirmed del luogo

una protezione: la vista *precise* non è sottoposta ad alcuna trasformazione ed espone le coordinate GPS esattamente come raccolte, per cui non è un vero livello di privacy ma la vista personale, non protetta, dell'utente sui propri dati. Le viste *approximate aggregated* sono ottenute con una tecnica di *spatial cloaking* [8]. Ogni coordinata GPS viene proiettata in Web Mercator (EPSG:3857) e riposizionata al centro della cella di una griglia di lato fisso a cui appartiene, 150 m per la vista *approximate*, 400 m per *aggregated*, prima di essere riproiettata in coordinate geografiche, come mostrato in Fig. 8.




Fig. 8. Generalizzazione spaziale a griglia: lo stesso punto reale viene pubblicato al centro della cella a cui appartiene; una cella più grande (*aggregated*) sposta il punto pubblicato più lontano da quello reale.

La Fig. 9 mostra lo stesso meccanismo su un viaggio reale: la traccia originale (linea continua) e la corrispondente vista *approximate* (linea tratteggiata), ottenuta sostituendo ogni punto con il centro della sua cella e collegando i centri consecutivi con segmenti retti.

1) *Costruzione del diario in base al livello di privacy*: I tre livelli di privacy incidono sulla rappresentazione geografica e sul dettaglio con cui vengono descritti i luoghi. Gli orari di



Fig. 9. Esempio su dati reali di un viaggio in auto: la linea continua è il percorso realmente registrato; la linea tratteggiata è la vista *approximate* (griglia da 150m) dello stesso percorso.

inizio e fine dei segmenti restano invece invariati in tutti i livelli. Nella vista *precise* nessun dato viene trasformato: ogni segmento mostra l'orario esatto di inizio e fine, il percorso GPS realmente registrato e, di conseguenza, la distanza realmente percorsa; per una sosta, viene mostrato il nome vero del luogo abituale a cui è stata associata, se esiste.

Nella vista *approximate*, il percorso mostrato non è più quello realmente registrato ma quello ottenuto dopo l'approssimazione a griglia descritta sopra: la distanza del segmento viene quindi ricalcolata su questo percorso approssimato, non su quello vero. Il nome del luogo associato a una sosta, invece, resta visibile come nella vista precisa: poiché la posizione è già protetta dall'approssimazione a griglia delle coordinate, mostrare anche il nome del luogo non aggiunge un rischio significativo ulteriore.

La vista *aggregated* applica la stessa trasformazione del percorso della vista approssimata, ma con una griglia più larga (400 m anziché 150 m), e in più nasconde anche l'identità dei luoghi: al posto del nome del luogo abituale mostra solo la sua categoria generica o un'etichetta neutra se la sosta non è associata a nessun luogo confermato.

IV. RISULTATI

A. Valutazione del riconoscimento HAR

Le valutazioni usano il validation set ufficiale SHL [1], mai impiegato per aggiornare i pesi. La Tabella III distingue la linea sperimentale dal modello.

TABLE III
CONFRONTO DELLE VARIANTI CNN+GRU SUL VALIDATION SET UFFICIALE

Variante	Canali	Sequenza	Accuracy
Produzione originale	6	32	79,47%
Produzione distribuita	6	128	84,88%

Le due varianti condividono lo stesso checkpoint CNN+GRU: cambia solo la lunghezza di sequenza usata in valutazione, non i pesi.

Poiché i pesi della GRU non dipendono dalla lunghezza della sequenza con cui viene interrogata, il layer applica la stessa trasformazione a ogni passo, indipendentemente da quanti passi compongono la sequenza, lo stesso checkpoint è stato valutato a più lunghezze di sequenza, per osservare l'andamento dell'accuratezza e verificare se il guadagno osservato passando da 32 a 128 continui, si stabilizzi o si inverta per lunghezze ancora maggiori. La Tabella IV e la Fig. 10 riportano l'andamento misurato sul validation set ufficiale (115.156 finestre).

TABLE IV
ACCURATEZZA DEL MODELLO DISTRIBUITO AL VARIARE DELLA LUNGHEZZA DI SEQUENZA

Lunghezza sequenza	Accuracy
32	79,46%
64	82,50%
128	84,88%
256	86,08%
512	86,38%




Fig. 10. Accuratezza sul validation set ufficiale al variare della lunghezza di sequenza data in ingresso alla GRU, a parità di pesi (nessun riaddestramento)

Il guadagno è marcato passando da 32 a 128 finestre (+5,4 punti), poi si riduce progressivamente (128→256: +1,2 punti; 256→512: +0,3 punti) senza però invertirsi: fino a 512 finestre (43 minuti di contesto) l'accuratezza continua a salire, sia pure con rendimenti marginali decrescenti. Non si osserva quindi, in questo intervallo, il plateau o il lieve calo ipotizzato oltre i 256; la scelta di 128 per la produzione resta un compromesso guidato dal costo di latenza (la GRU bidirezionale non scala linearmente su CPU), non dal raggiungimento di un punto di saturazione dell'accuratezza.

Questo guadagno di accuratezza da solo non giustifica però un aumento di L in produzione: la latenza è stata misurata direttamente sul codice e sul modello reali (HARClassifier), nello stesso processo, a caldo, per ciascuna lunghezza di sequenza e per dimensioni di richiesta realistiche.

Il costo di avvio (*warmup*, la compilazione del grafo effettuata una volta per processo worker) cresce da 30,4 s a 128 finestre a 166,2 s a 512, un fattore $5,5\times$. Sulla dimensione di

TABLE V
LATENZA DI HARCCLASSIFIER AL VARIARE DELLA LUNGHEZZA DI
SEQUENZA (MS)

L	100	500	1000	2000	Warmup
32	81,7	131,0	567,0	921,7	7,2 s
64	87,4	211,3	659,4	1186,0	15,0 s
128	130,9	265,9	507,0	1212,7	30,4 s
256	345,2	404,1	947,0	1479,1	73,2 s
512	605,1	518,3	982,5	1299,5	166,2 s

richiesta più piccola (100 finestre), la latenza a caldo passa da 130,9 ms a 605,1 ms, un fattore $4,6\times$. A fronte di questi costi, il guadagno di 1,5 punti di accuratezza rispetto a 128 non è sufficiente a giustificare il passaggio a $L = 512$ in produzione: la scelta di $L = 128$ resta motivata dal costo di latenza, ora misurato direttamente e non solo ipotizzato, e non da un plateau di accuratezza già raggiunto.

Per valutare il modello distribuito sono state usate 115.156 finestre. I valori grezzi dei primi sei canali sono stati ripristinati dal tensore normalizzato prima dell'inferenza.

Le sequenze sono state costruite separatamente per ciascuna delle quattro posizioni corporee. In questo modo il contesto della GRU non attraversa registrazioni indipendenti.

L'accuracy è 84,88%. Precision, recall e F1 macro sono 87,67%, 77,12% e 80,08%; le corrispondenti medie pesate sono 85,60%, 84,88% e 84,30%.

L'errore dominante è la confusione tra `IDLE` e `MOVING_VEHICLE`. Un veicolo fermo a un semaforo o nel traffico può produrre un segnale simile a quello di una persona ferma.

La classe `BIKING` ha recall 0,414: viene confusa soprattutto con `WALKING` e `MOVING_VEHICLE`. `RUNNING` ha precision 0,998 ma recall 0,754, anche per il supporto ridotto.

B. Discussione dei casi ambigui

La confusion matrix (Tabella VII) permette di analizzare quantitativamente alcuni casi che la sola accuracy nasconderebbe.

1) *Veicolo fermo nel traffico o a un semaforo*: È il caso ambiguo più frequente: 3.009 finestre reali `IDLE` vengono classificate come `MOVING_VEHICLE` e, simmetricamente, 6.346 finestre reali `MOVING_VEHICLE` vengono classificate come `IDLE`. Il segnale accelerometrico e giroscopico di un veicolo fermo è infatti indistinguibile, su una singola finestra di 5 s, da quello di una persona ferma: l'informazione che li distingue, una velocità media diversa da zero nei minuti circostanti, esiste solo a livello di sequenza, non di singola finestra isolata.

2) *Cammino veloce confuso con la bicicletta*: `BIKING` ha il recall più basso del modello (0,414): 2.581 finestre reali di bicicletta vengono classificate come `WALKING` e 2.753 come `MOVING_VEHICLE`. Un cammino sostenuto o una discesa in bicicletta a bassa velocità producono profili di accelerazione sovrapposti, e `BIKING` ha inoltre il supporto più basso tra le classi frequenti (9.624 finestre), rendendo il confine di decisione meno stabile.

3) *Fermate temporanee durante uno spostamento*: Una sosta breve (es. attesa a un incrocio durante una camminata) può generare qualche finestra isolata classificata `IDLE` in mezzo a una sequenza altrimenti `WALKING`. A livello di singola finestra questo è un errore locale coerente con l'analisi precedente; la segmentazione del diario (Sezione III) non lo propaga come sosta a sé stante, perché riassegna all'etichetta circostante ogni gruppo di finestre con etichetta diversa che duri meno di 60 s (Fig. 5), una finestra isolata non genera quindi una sosta spuria nel diario finale.

4) *Cambio di mezzo di trasporto*: Un cambio reale di modalità (es. da `WALKING` a `MOVING_VEHICLE` salendo su un autobus) produce necessariamente alcune finestre di transizione ambigue nell'intorno del cambio, mentre il segnale sensoriale converge verso il nuovo pattern di moto. Questo caso va distinto dal precedente: non viene rimosso dallo smoothing (è un cambio reale, non rumore da correggere), ma diventa il confine tra due segmenti del diario non appena la sequenza di etichette si stabilizza nella nuova modalità.

La fusione del modello in un unico grafo e la chiamata in batch riducono il costo di inferenza rispetto alla pipeline a due stadi originale, senza cambiare i pesi né l'accuracy: il guadagno di velocità deriva dal pattern di chiamata, quello di accuratezza dal contesto più lungo dato alla GRU. Sono quindi due effetti distinti, entrambi discussi con numeri nella Tabella III e nella Tabella V.

C. Compromesso privacy/utilità

Le metriche di Privacy Perturbation e Quality of Service definite in Sezione III sono state calcolate sull'insieme dei viaggi realmente registrati nel database, segmento per segmento: separatamente per i segmenti di movimento, raggruppati per modalità di attività riconosciuta, e per i segmenti di sosta, per cui la perturbazione è calcolata sul centroide GPS della sosta anziché sulla lunghezza di un percorso. La Tabella VIII riporta i risultati.

La Privacy Perturbation cresce con la dimensione della cella, come atteso: passando da *approximate* (150 m) ad *aggregated* (400 m) la distanza media tra punto reale e punto pubblicato più che raddoppia in tutte le modalità, comprese le soste. La Quality of Service, invece, non peggiora sempre in modo monotono con l'aggregazione: per i segmenti in auto l'errore relativo di distanza è leggermente più basso con celle più grandi (0,61 contro 0,64) che con celle più piccole. Il campione di segmenti in bicicletta è troppo piccolo ($n=3$) per trarne conclusioni robuste, ed è riportato solo per completezza.

D. Latenza della pipeline di ingestione

Per misurare il tempo impiegato dalle diverse fasi della pipeline di caricamento ed elaborazione di un viaggio è stato eseguito un test di carico con un client sintetico che riproduce il comportamento dell'applicazione mobile reale (Sezione III). Sono stati simulati 25 utenti che caricano contemporaneamente viaggi di circa un'ora: poiché un utente non può avere più di un viaggio in corso alla volta (Sezione III), ciascuno ha caricato i propri viaggi in sequenza, uno alla volta, per un

TABLE VI
METRICHE PER CLASSE DEL MODELLO CNN+GRU A SEI CANALI DISTRIBUITO IN PRODUZIONE

Classe	Supporto	Precision	Recall	F1
IDLE	23.856	0,737	0,855	0,792
WALKING	20.920	0,848	0,946	0,894
RUNNING	2.220	0,998	0,754	0,859
BIKING	9.624	0,906	0,414	0,569
MOVING_VEHICLE	58.536	0,894	0,887	0,890

TABLE VII
CONFUSION MATRIX DEL MODELLO CNN+GRU A SEI CANALI DISTRIBUITO; RIGHE REALI E COLONNE PREDETTE

Reale \ predetta	IDLE	WALK	RUN	BIKE	VEHICLE
IDLE	20.395	346	0	106	3.009
WALKING	626	19.786	3	92	413
RUNNING	0	332	1.674	213	1
BIKING	301	2.581	0	3.989	2.753
MOVING_VEHICLE	6.346	285	0	2	51.903




Fig. 11. Trade-off misurato tra protezione della posizione e utilità. La griglia più ampia aumenta sempre la perturbazione, mentre la distorsione della distanza dipende dalla geometria e dalla lunghezza tipica dei segmenti di ciascuna modalità.

TABLE VIII
PRIVACY PERTURBATION MEDIA E QUALITY OF SERVICE (ERRORE RELATIVO DI DISTANZA) PER MODALITÀ, SUI DUE LIVELLI PROTETTI

Modalità	n	Perturbation (m)		QoS (err. rel.)	
		approx.	aggr.	approx.	aggr.
Veicolo	38	37,3	100,3	0,64	0,61
A piedi	56	41,9	93,0	0,93	1,06
Bicicletta	3	44,8	82,3	0,50	1,28
Sosta	51	35,7	97,5	—	—

TABLE IX
LATENZA MEDIA DELLE FASI DELLA PIPELINE DI INGESTIONE (250 VIAGGI, 25 UTENTI CONCORRENTI)

Fase	Media	Dev.std	Min	Max
Core (GPS+transizioni)	2,02 s	2,61 s	0,25 s	15,83 s
Upload raw (client)	3,04 s	2,56 s	0,43 s	28,59 s
HAR + diario	4,62 s	1,50 s	1,99 s	11,06 s
Batch insert raw	29,68 s	8,235 s	20,39 s	53,97 s
Data mining luoghi	0,97 s	0,64 s	0,27 s	2,74 s

totale di 10 viaggi a testa (250 viaggi complessivi). La fase di upload raw è stata cronometrata lato client; le altre quattro fasi, lato backend. Il test è stato eseguito su un ambiente locale equivalente a quello di produzione (stessi container Docker), non sull'hardware di produzione stesso: i valori assoluti vanno quindi letti come indicativi, mentre le proporzioni relative tra le fasi restano informative.

La fase nettamente più onerosa è l'inserimento in batch dei dati sensoriali grezzi (media 29,68 s, fino a quasi 1 minuto nel caso peggiore), dovuto al volume di righe scritte in RawSensorReading, una per ogni campione, quindi fino a 360.000 righe per un singolo viaggio di un'ora (720 finestre da 500 campioni). L'inserimento usa già bulk_create a gruppi di 5000 righe (72 batch per un viaggio di un'ora),

quindi il costo non è dovuto a query singole per riga, ma al volume assoluto di dati scritti a questa granularità, aggravato dalla contesa sul database sotto 25 utenti concorrenti. Va però notato che il batch insert dei dati grezzi non è una fase percepita dall'utente: il diario del viaggio è già disponibile non appena termina la fase HAR, mentre la persistenza dei dati grezzi prosegue in background. La latenza effettivamente percepita dall'utente, core, upload raw e HAR/diario, resta quindi complessivamente bassa, dell'ordine di pochi secondi.

Per correttezza va infine segnalato che la velocità della fase HAR è in parte dovuta al fatto che il modello viene caricato in memoria una sola volta all'avvio di ciascun processo worker Celery (warm_har_model_on_worker_start, agganciato al segnale worker_process_init), anziché ad

ogni singola richiesta di inferenza. Questo rende l'inferenza rapida a runtime, ma ha come contropartita un utilizzo di RAM elevato per ciascun worker, dato il peso del modello tenuto costantemente in memoria.

Questo suggerisce due direzioni per un'eventuale scalatura del sistema oltre il semplice aumento del numero di worker. La prima riguarda proprio il modello HAR: passare da una copia caricata in RAM per ciascun worker a un'unica istanza condivisa, interrogata dai worker come servizio separato, ridurrebbe l'occupazione di memoria aggregata a scapito di una latenza leggermente più alta sulla singola richiesta di inferenza, un compromesso favorevole quando l'obiettivo è aumentare il numero di worker eseguibili in parallelo sulla stessa macchina. La seconda riguarda il database: durante il test di carico è stato il componente più sollecitato in assoluto (più dei worker Celery stessi), per cui scalare orizzontalmente il sistema richiederebbe anche di replicare il database e introdurre una logica di sincronizzazione tra le repliche, oltre alla sola duplicazione dei worker applicativi.

Dichiarazione sull'utilizzo di strumenti di Intelligenza Artificiale

Nello sviluppo di questo progetto è stato utilizzato Claude (Anthropic), tramite l'interfaccia Claude Code, in due ambiti distinti.

1) *Confronto e ricerca*: Lo strumento è stato usato come supporto alla ricerca e al confronto di idee e scelte progettuali, in particolare per raccogliere e confrontare più fonti/approcci con relativi pro e contro, in tempi più rapidi rispetto a una ricerca manuale condotta fonte per fonte.

2) *Scrittura di codice*: Lo strumento è stato usato per:

- supportare lo sviluppo dell'interfaccia grafica finale dell'applicazione mobile e della dashboard web;
- refactoring e pulizia del codice esistente, in particolare lato frontend/mobile, per farlo aderire il più possibile all'architettura scelta per il progetto;
- scrivere piccole porzioni di codice per gestire casi limite lato backend;
- scrittura dei DTO (Data Transfer Object) lato frontend, usati per mappare le risposte JSON delle API REST del backend nei modelli dati dell'applicazione mobile e della dashboard web.

La progettazione dell'architettura, la raccolta e l'elaborazione dei dati, l'implementazione delle pipeline di training e valutazione del modello HAR, e tutte le decisioni progettuali del sistema sono opera dello studente, che dichiara di comprendere integralmente il codice e i contenuti presentati in questa relazione.

CONCLUSIONE

In questo lavoro ho presentato Mobility Diary, un sistema context-aware per la costruzione di un diario personale di mobilità, composto da un'applicazione mobile, un back-end che ne gestisce l'elaborazione asincrona e una dashboard amministrativa. Il sistema integra una macchina a stati finiti per il rilevamento del movimento, un modulo di riconoscimento

dell'attività umana basato su CNN1D e GRU, e meccanismi di generalizzazione spaziale per proteggere la posizione dell'utente su tre livelli di privacy.

Il modulo HAR raggiunge un'accuratezza dell'84,88% sul validation set ufficiale dopo l'ottimizzazione per l'inferenza in produzione. Sul fronte privacy, l'analisi condotta sui viaggi realmente registrati mostra che la Privacy Perturbation cresce in modo prevedibile con la dimensione della cella di generalizzazione, mentre l'effetto sull'utilità del dato varia a seconda della modalità di movimento: per gli spostamenti in auto, tipicamente lunghi e rettilinei, la Quality of Service resta pressoché stabile anche con la griglia più larga, mentre per la camminata, fatta di percorsi più brevi, l'aggregazione comporta una perdita di utilità più marcata.

Sul fronte delle prestazioni, il test di carico sulla pipeline di ingestione mostra che la latenza effettivamente percepita dall'utente, upload dei dati e classificazione HAR, dopo la quale il diario è già consultabile, resta dell'ordine di pochi secondi, mentre la persistenza dei dati sensoriali grezzi, molto più lenta, avviene in background senza impatto percepito. Sotto carico concorrente il database si conferma il componente più sollecitato, indicando che una futura scalata del sistema richiederebbe la sua replica, oltre a un modello HAR condiviso tra i worker invece che duplicato in RAM su ciascuno.

Il sistema presenta comunque dei limiti. La macchina a stati finiti che rileva il movimento è un'euristica costruita ad hoc su accelerometro e GPS, ed è verosimilmente meno precisa delle API di riconoscimento dell'attività fornite nativamente dal sistema operativo del telefono, che non sono state utilizzate. Il modulo HAR, inoltre, non distingue tra le diverse modalità di trasporto motorizzato, auto, autobus, treno, che vengono tutte classificate in un'unica etichetta `MOVING_VEHICLE`.

Due direzioni di sviluppo futuro appaiono particolarmente rilevanti. La prima è l'introduzione di un processo periodico che elimini dallo storage a oggetti i dati sensoriali grezzi di un viaggio una volta che la sua elaborazione è completata: attualmente questi dati non vengono mai rimossi automaticamente, e restano nello storage indefinitamente a meno che l'utente non cancelli esplicitamente il viaggio. La seconda è un meccanismo con cui l'utente possa correggere le etichette di attività assegnate dal modulo HAR quando errate (ad esempio segnalando che un tratto indicato come cammino era in realtà percorso in auto), e una pipeline che raccolga queste correzioni per aggiornare periodicamente i pesi del modello.

REFERENCES

- [1] "Sussex-Huawei Locomotion & Transportation Dataset." [Online]. Available: <http://www.shl-dataset.org/>. Accessed: Sep. 14, 2026.
- [2] PostGIS Project, "PostGIS Manual: Geography Data Type and ST_Length." [Online]. Available: https://postgis.net/docs/using_postgis_dbmanagement.html and https://postgis.net/docs/ST_Length.html. Accessed: Sep. 13, 2026.
- [3] Timescale, "Hypertables," *Timescale Documentation*. [Online]. Available: <https://docs.timescale.com/use-timescale/latest/hypertables/>. Accessed: Sep. 13, 2026.
- [4] Mapbox, "Geocoding API and Directions API," *Mapbox API Documentation*. [Online]. Available: <https://docs.mapbox.com/api/search/geocoding/> and <https://docs.mapbox.com/api/navigation/directions/>. Accessed: Sep. 13, 2026.

- [5] J. Brownlee, "1D Convolutional Neural Network Models for Human Activity Recognition," *Machine Learning Mastery*. [Online]. Available: <https://machinelearningmastery.com/cnn-models-for-human-activity-recognition-time-series-classification/>. Accessed: Sep. 14, 2026.
- [6] "Gated Recurrent Unit Networks," *GeeksforGeeks*. [Online]. Available: <https://www.geeksforgeeks.org/machine-learning/gated-recurrent-unit-networks/>. Accessed: Sep. 14, 2026.
- [7] S. Yildirim, "DBSCAN Clustering – Explained," *Towards Data Science*. [Online]. Available: <https://towardsdatascience.com/dbscan-clustering-explained-97556a2ad556/>. Accessed: Sep. 14, 2026.
- [8] "Spatial Cloaking," *Wikipedia*. [Online]. Available: https://en.wikipedia.org/wiki/Spatial_cloaking. Accessed: Sep. 14, 2026.
- [9] A. Avvenuti, "Pine: A Lightweight Architecture Helper for your Flutter Projects," *Medium*. [Online]. Available: <https://angeloavv.medium.com/pine-a-lightweight-architecture-helper-for-your-flutter-projects-1ce69ac63f74>. Accessed: Sep. 14, 2026.